

基于条件生成对抗网络的草图提示商品图像生成系统

黄正扬

人工神经网络课程作业

项目地址: <https://github.com/hzycool/edge2product-pix2pix>

摘要: 本实验围绕“边缘草图到商品图像”的图像到图像翻译任务, 基于 Pix2Pix 条件生成对抗网络实现了鞋类草图到彩色商品图像的生成系统。模型采用 U-Net 作为生成器、PatchGAN 作为判别器, 并联合使用对抗损失和 L1 重建损失进行训练。实验使用 edges2shoes 数据集, 在 CPU 环境下抽取 100 对训练图像训练 5 个 epoch, 并在 20 对验证图像上进行推理和评价。实验结果显示, 生成器总损失由第 1 个 epoch 的 38.2775 下降到第 5 个 epoch 的 19.9973; 在验证图像上得到 Mean L1 为 0.3447、PSNR 为 7.08、SSIM 为 0.3414。可视化结果表明, 模型能够保持鞋子的大致轮廓和位置关系, 但颜色稳定性与局部纹理仍受小样本训练规模限制。除模型训练外, 本项目还整理了推理、评价、可视化、Gradio 演示界面、LaTeX 报告和 GitHub 开源仓库, 形成了一个可复现实验流程。

关键词: 生成对抗网络; Pix2Pix; 条件 GAN; 图像到图像翻译; 草图生成; 深度学习

一、引言

生成对抗网络 (Generative Adversarial Network, GAN) 是深度生成模型中的重要方法。GAN 由生成器和判别器组成: 生成器尝试合成接近真实分布的样本, 判别器则判断输入样本来自真实数据还是生成器。二者在训练中形成对抗关系, 使生成器逐步学习数据分布。相比传统的判别式模型, GAN 更强调从数据中学习“如何生成”样本, 因此在图像生成、图像修复和图像翻译等任务中具有较强的代表性。

本实验关注的是有条件的图像生成任务。对于鞋类草图到商品图像的转换, 输入边缘图已经提供了鞋子的外部轮廓和主要结构, 模型需要在此条件下补充颜色、明暗和局部纹理。Pix2Pix 是一种面向成对图像翻译任务的条件 GAN 方法, 适合处理边缘图到照片、标签图到街景等监督式图像转换问题。因此, 本实验选择 Pix2Pix 作为主要模型, 在 edges2shoes 数据集上完成“边缘草图 → 鞋类商品图像”的小样本实验, 并将训练、推理、评价和展示过程整理为完整项目。

二、相关工作

Goodfellow 等人提出的 GAN[1] 通过最小最大博弈建立生成模型, 为后续图像生成研究提供了基础框架。普通 GAN 通常从随机噪声出发生成样本, 而条件 GAN 在生成过程里引入额外条件, 使输出受到类别、文本或图像等信息控制。对于图像翻译任务, 条件输入通常就是待转换的图像。

Pix2Pix[2] 将条件 GAN 用于成对图像到图像翻译, 并引入 U-Net 生成器和 PatchGAN 判别器。该方法的一个特点是同时使用对抗损失和 L1 重建损失: 前者鼓励生成图像更真实, 后者约束输出与目标图像在像素层面接近。CycleGAN[3] 则主要用于非成对图像数据, 通过循环一致性约束学习两个域之间的映射。由于 edges2shoes 数据集提供了边缘图和鞋子照片的成对样本, 本实验采用 Pix2Pix 比采用非成对方法更直接, 也便于分析训练目标与实验结果。

三、方法

3.1 任务定义

设输入边缘草图为 x , 目标商品图像为 y 。实验目标是训练生成器 G , 使输出 $G(x)$ 尽可能接近真实目标图像 y 。判别器 D 的输入是条件图像与目标图像的拼接, 即 (x, y) 或 $(x, G(x))$, 输出为局部 patch 的真伪判断。

3.2 生成器结构

生成器采用 U-Net 编码器-解码器结构。编码器通过逐层下采样提取高层特征, 解码器通过逐层上采样恢复图像空间尺寸。U-Net 的跳跃连接将浅层边缘信息传递到解码阶段, 有助于保留鞋底、鞋面边界和整体外形。对于草图到图像的转换任务, 这种结构比普通编码器-解码器更适合保持输入轮廓。

3.3 判别器结构

判别器采用 PatchGAN 结构。PatchGAN 并不直接对整张图像给出一个真伪标量, 而是对图像局部区域进行判断。这样可以让判别器更关注局部纹理、边缘连续性和颜色块的自然程度, 同时保持较少的参数量。训练时, 真实图像对被标记为正样本, 生成图像对被标记为负样本。

3.4 损失函数

生成器损失由对抗损失和 L1 重建损失组成:

$$\mathcal{L}_G = \mathcal{L}_{GAN}(G, D) + \lambda_{L1} \mathcal{L}_1(G), \quad (1)$$

其中 $\lambda_{L1} = 100$ 。较大的 L1 权重可以让训练前期更加稳定, 并鼓励输出图像与成对标注图像保持一致。判别器则通过区分真实图像对和生成图像对进行优化。

四、数据集与实验设置

实验使用 edges2shoes 数据集。该数据集中每张样本图像由左右两部分拼接而成, 一侧为鞋子的边缘图, 另一侧为对应的鞋子照片。程序读取图像后从中间切

分，并按照 AtoB 方向将边缘图作为输入、真实照片作为目标图像。为保证实验在普通 CPU 环境下也能运行，本次实验从原始训练集中抽取 100 对图像，并使用 20 对验证图像进行推理和评价。

表 1 主要实验参数

参数	取值
输入尺寸	256 × 256
训练样本数	100
验证样本数	20
训练轮数	5
Batch size	1
学习率	0.0002
λ_{L1}	100
训练设备	CPU

评价指标使用 Mean L1、PSNR 和 SSIM。Mean L1 反映生成图像与目标图像之间的平均像素误差；PSNR 常用于评价重建质量；SSIM 用于衡量图像结构相似性。除定量指标外，实验还保存输入草图、目标图像和生成图像的三列对比图，用于观察模型是否保持轮廓以及是否生成合理的颜色区域。

五、 系统实现

项目使用 PyTorch[4] 实现。数据集模块负责加载成对图像、切分左右半图、调整尺寸，并将像素值归一化到 $[-1, 1]$ 。模型模块包括 U-Net 生成器、PatchGAN 判别器、损失函数以及 Pix2Pix 训练封装。训练脚本会在每个 epoch 后记录 G loss、D loss、GAN loss 和 L1 loss，并保存样例生成图。

推理阶段只加载训练好的生成器，对验证图像中的边缘草图进行转换，并将输出反归一化到普通图像格式。评价脚本按照文件名匹配 generated 与 target 图像，计算 Mean L1、PSNR 和 SSIM，并同时保存 JSON 与 Markdown 格式的指标结果。项目还提供了 Gradio 演示界面，用于上传草图并展示生成结果。代码、报告和轻量实验结果已整理到 GitHub 仓库，项目地址见标题区。

六、 实验结果

图 1 展示了 5 个 epoch 的训练损失变化。生成器总损失和 L1 损失在前两轮下降较明显，之后下降速度变慢。第 1 个 epoch 的 L1 损失为 36.9426，第 5 个 epoch 降至 18.3201，说明模型已经学习到一部分从边缘图到鞋子照片的对应关系。




图 1 训练损失曲线

表 2 各 epoch 的平均训练损失

Epoch	G loss	D loss	GAN loss	L1 loss
1	38.2775	0.5904	1.3349	36.9426
2	24.6648	0.4530	1.7312	22.9336
3	22.2763	0.4526	1.6241	20.6521
4	21.2839	0.4341	1.7277	19.5563
5	19.9973	0.4454	1.6771	18.3201

表 3 20 对验证图像上的评价指标

样本数	Mean L1 ↓	PSNR ↑	SSIM ↑
20	0.3447	7.08	0.3414

从表 3 可以看出，模型的重建质量还不高。PSNR 和 SSIM 数值偏低，说明在颜色和纹理细节上仍有明显误差；但 Mean L1 与损失曲线共同说明，小样本训练已经能够完成基本的映射学习。对于课程实验而言，本次结果更适合用于验证 Pix2Pix 的完整流程，而不是证明模型已经具备成熟的商品图生成质量。

七、 结果分析

从图 2 可以观察到，生成图像大体跟随了输入草图的鞋子轮廓，鞋底和鞋面的空间位置基本对应。这说明 U-Net 中的跳跃连接对保留结构信息是有帮助的。另一方面，生成结果的颜色不够稳定，局部纹理较为模糊，部分区域会出现灰色或平滑块。这与训练样本较少、训练轮数较短以及 L1 损失的平均化倾向有关。

判别器损失在 0.43 到 0.59 之间波动，没有出现明显崩溃，但小样本条件下的判别器很难学习到充分多样的局部纹理分布。对抗损失能够改善局部真实感，但当训练数据不足时，它也容易受到样本分布有限的影响。因此，本实验中模型更擅长恢复大致形状，而不是生成清晰且稳定的鞋面材质。

八、 交互界面与项目发布

为便于课堂展示，项目实现了一个 Gradio[5] 演示界面。用户可以上传一张边缘草图，点击生成按钮后，



图 2 输入草图、目标图像和生成图像对比。每行从左到右分别为 input、target 和 generated。

程序调用训练好的生成器输出鞋类商品图像。该界面主要用于说明模型推理流程，实际生成效果仍取决于训练规模和 checkpoint 质量。




图 3 交互界面示意图

项目已经上传到 GitHub，仓库链接为题名区所列的 [Edge2Product 项目主页](#)。仓库中包含代码、小样本数据、实验曲线、推理结果、评价指标和本报告 PDF。完整 edges2shoes 数据集和大型模型权重没有直接放入普通仓库，使用者可根据 README 中的脚本重新下载数据并训练模型。

九、 不足与改进方向

本实验的主要不足是训练规模较小。100 对样本不足以覆盖鞋子外观的多样性，5 个 epoch 也不足以让 GAN 训练充分收敛。此外，Pix2Pix 依赖成对数据，如果应用到没有配对图像的场景，需要考虑 CycleGAN 等非成对图像翻译方法。

后续可以从三个方面改进。第一，在 GPU 环境下使用更多样本和更多训练轮数；第二，在损失函数中加入感知损失或特征匹配损失，以改善纹理细节；第三，与 CycleGAN、CUT 等方法进行对比实验，分析不同图像翻译方法在草图到商品图像任务上的差异。

十、 总结

本实验实现了基于 Pix2Pix 的鞋类边缘草图到商品图像生成系统。通过训练 U-Net 生成器和 PatchGAN 判别器，模型能够根据输入草图生成大致符合轮廓的鞋子图像。实验结果表明，在 100 对训练样本和 5 个 epoch 的设置下，损失具有下降趋势，但生成图像仍存在颜色不稳定和纹理模糊的问题。通过本次实验，我对条件 GAN、Pix2Pix 模型结构、成对图像数据处理以及生成模型评价指标有了更直观的理解，也完成了一

个包含训练、推理、评价、展示和项目发布的完整深度学习流程。

参考文献

- [1] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial nets. In *Advances in Neural Information Processing Systems*, 2014.
- [2] Phillip Isola, Jun-Yan Zhu, Tinghui Zhou, and Alexei A. Efros. Image-to-image translation with conditional adversarial networks. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2017.
- [3] Jun-Yan Zhu, Taesung Park, Phillip Isola, and Alexei A. Efros. Unpaired image-to-image translation using cycle-consistent adversarial networks. In *Proceedings of the IEEE International Conference on Computer Vision*, 2017.
- [4] PyTorch Contributors. Pytorch documentation. <https://pytorch.org/docs/>, 2026.
- [5] Gradio Contributors. Gradio documentation. <https://www.gradio.app/docs/>, 2026.